CS101 · ПРОЄКТ

ХОЛОДНИЙ СТАРТ У РЕКОМЕНДАЦІЙНИХ СИСТЕМАХ

Як графові нейронні мережі (GNN) допомагають рекомендувати нові товари без історії взаємодій

Команда з 5 учасників

СЛАЙД 2

ХТО І НАД ЧИМ ПРАЦЮВАВ

Слайди 3–4	**Занько Марія**	Постановка проблеми: типи cold start, підходи до розв’язання, чому граф
Слайди 5–6	**Сергій Муха**	Гетерогенний граф і message passing: як новий товар отримує опис від сусідів
Слайди 7, 12	**Ігор Кваленков**	Алгоритми GNN: GraphSAGE, GAT, LightGCN та їхня поведінка на cold start
Слайди 8–9	**Кальмус Ян**	Датасет Amazon і симуляція cold start
Слайди 10–11, 13–14	**Радківський Ілля**	Метрики, результати Pinterest, обмеження та досвід індустрії

СЛАЙД 3

ХОЛОДНИЙ СТАРТ: ЩО ЦЕ І ЧОМУ КЛАСИЧНІ МЕТОДИ ТУТ СЛАБКІ

1) Три типи cold start

USER COLD START

Новий користувач: ще немає кліків і покупок

ITEM COLD START

Новий товар: немає взаємодій. **Наш фокус**

SYSTEM COLD START

Нова платформа: немає ні користувачів, ні історії

Cold start ≠ sparsity: історії **немає зовсім** ≠ історії **мало**

2) Чому CF і матрична факторизація тут не працюють

$$\hat{y}ui = pu \cdot qi$$

вектор на кожен ID

- Вектор **кожного ID** навчається на взаємодіях
- Новий ID: взаємодій немає, вектор **не навчений** (випадковий)
- Запасний варіант: **Popularity**, але без персоналізації

СЛАЙД 4

ПІДХОДИ ДО РОЗВ’ЯЗАННЯ І ЧОМУ ГРАФ

Підхід	Які дані потрібні	Як вирішує cold start	Обмеження
Без даних про об’єкт: Popularity, random, опитування, bandit	глобальна статистика	показує популярне, досліджує	немає персоналізації
Content-based і гібридні (LightFM)	ознаки об’єкта	вектор будується з ознак	залежить від ознак; без зв’язків
Глибокі з ознаками (DropoutNet, Heater)	ознаки + історія	«вимикає» історію під час навчання	потрібні якісні ознаки
Meta-learning (MeLU, MAMO, MetaEmbedding)	багато малих задач	швидка адаптація за кількома прикладами	складне навчання
Графові (GCMC, IGMC, STAR-GCN, PinSage, hetero GNN)	граф + ознаки	сигнал від сусідів і зв’язків	вартість; якість зв’язків
Контрастне (CLCRec)	ознаки + взаємодії	вирівнює простори ознак і взаємодій	складне налаштування

Чому граф?

Зв’язки (бренд, категорія, теги) несуть сигнал навіть без взаємодій. GNN поширює його через сусідів (message passing).

Дослідницьке питання

Чи дає граф приріст понад самі ознаки на нових товарах?
H1: GraphSAGE з ознаками > Popularity
H2: GraphSAGE > content-only

СЛАЙД 5

ГЕТЕРОГЕННИЙ ГРАФ: НАВІЩО ВІН ПОТРІБЕН НОВОМУ ТОВАРУ

1) Холодний старт товару

Телефон уже є в каталозі, але його ніхто не купив. Звичайні рекомендації дивляться на минулі покупки, тому показати його нікому.

2) Схема «людина — товар» для нього порожня

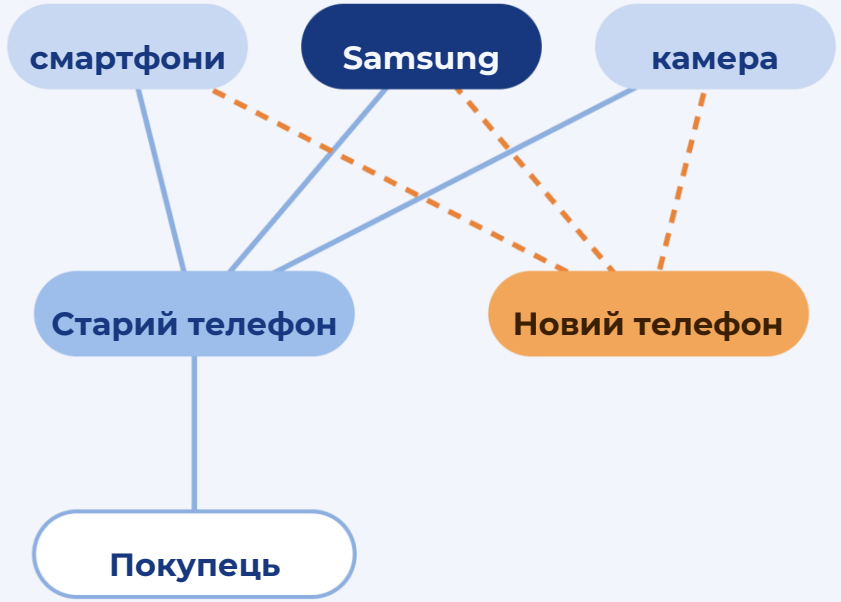
Немає лінії до людей, отже немає сусідів і немає звідки взяти опис.

3) Додають бренд, категорію і мітку

Старий і новий телефон обидва з'єднані з Samsung, категорією «смартфони» і міткою «камера». Напряму вони не з'єднані: шлях іде через Samsung.

4) Лінія потрібна в обидва боки

«Телефон → Samsung»: бренд бачить телефони. Зворотна лінія «Samsung → телефон» потрібна, щоб новий телефон побачив бренд.



Пунктир і помаранчевий — новий товар без жодних покупок

СЛАЙД 6

ЯК ТОЧКА ЗБИРАЄ ОПИС ВІД СУСІДІВ

1) Крок проходять усі точки одразу

Сусіди телефону N не змінюються: Samsung, «смартфони», «камера». Змінюються числа в їхніх списках.

2) За один крок новина проходить одну лінію

N читає списки сусідів з попереднього кроку, а не ті, що вони рахують просто зараз.

3) До покупця три лінії, отже три кроки

Покупець → старий телефон → Samsung → новий телефон. На третьому кроці N дізнається, хто купував інші телефони цього бренду.

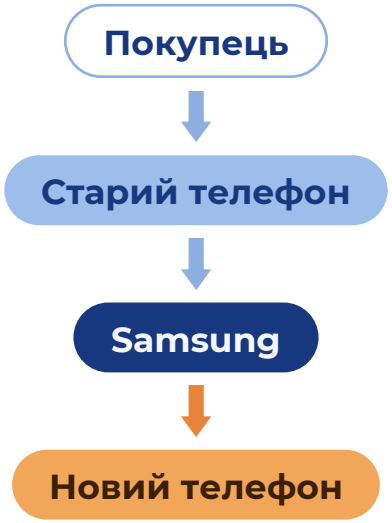
4) Навчання змінює коефіцієнти, не числа з картки

Новий телефон чіпляють до вже наявних точок і один раз проганяють ту саму формулу.

ФОРМУЛА ОДНОГО КРОКУ

новий опис = (свій старий опис + середнє сусідів) / 2

Шлях новини за три кроки



СЛАЙД 7

ПРИНЦИП РОБОТИ, СИЛЬНІ Й СЛАБКІ СТОРОНИ GNN-МОДЕЛЕЙ

1) GraphSAGE (SAmple and aggreGAtion)

Принцип роботи: Для кожного вузла випадковим чином семплюється фіксована кількість сусідів (1-го, 2-го порядку тощо), після чого їхні фічі агрегуються (через Mean, LSTM або Pooling). Навчає функції агрегації, а не самі ембеддинги.

Сильні сторони: Висока масштабованість на великих графах; підтримує індуктивне навчання (легко обробляє нові вузли).

Слабкі сторони: Можлива втрата контексту через випадковий вибір сусідів замість урахування всього оточення.

2) GAT (Graph Attention Network)

Принцип роботи: Використовує механізм Self-Attention для розрахунку динамічних ваг сусідів. Вплив кожного сусіда визначається тим, наскільки його атрибути важливі для поточного вузла.

Сильні сторони: Висока точність; адаптивність до важливості окремих зв'язків у графі.

Слабкі сторони: Високі обчислювальні витрати O(|V| + |E|) та високі вимоги до пам'яті через матриці уваги.

3) LightGCN (Light Graph Convolutional Network)

Принцип роботи: Спрощена модель для рекомендаційних систем. Вилучено нелінійні активації та вагові матриці W. Ембеддинги формуються як зважена сума векторів сусідів на різних шарах.

Сильні сторони: Дуже швидке навчання; висока точність у задачах коллаборативної фільтрації (User-Item graphs).

Слабкі сторони: Повністю залежить від ID вузлів і не використовує додаткові атрибути (Node Features).

СЛАЙД 8

ДАТАСЕТИ ДАНИХ

Для дослідження обрано реальний датасет телефонної продукції від Amazon. Він містить і поведінкову історію, і характеристики пристроїв

Телефони з Amazon обрано саме тому, що вони мають характеристику “Бренд” та “Модель”, чого немає в інших датасетах, як в фільмах (MovieLens)

Для рекомендацій є важливий факт задоволеності покупкою: якщо рейтинг товару більше 4 зірок, їх переведено в активні зв’язки, а оцінки з 1, 2 або 3 зірками відкинуто

СЛАЙД 9

СИМУЛЯЦІЯ COLD START

Із 4 моделей телефонів (Samsung, BlackBerry, HTM, Jethro) 3 моделі призначено “теплими” — на цих значеннях модель вчиться будувати зв’язки

Samsung
тепла: є історія

BlackBerry
тепла: є історія

HTM
cold: ребра видалено

Jethro
тепла: є історія

1

З навчального графа спеціально видалено ребра з моделі HTM. Для моделі у цього товару немає історії продаж.

2

У графі тільки залишено характеристики пристрою: його тип, ціна та бренд. Завдання GNN поєднати новий товар з потрібними покупцями.

3

Усі справжні взаємодії користувачів з телефоном відведено в інший файл (true_results). Після навчання дані моделі звіряються з прихованими фактами.

СЛАЙД 10

МЕТРИКИ РАНЖУВАННЯ ТА ВАЛІДАЦІЯ ОБЧИСЛЕНЬ.

1) Recall@K

повнота серед топ-K

Виражає частку знайдених релевантних об’єктів відносно всіх, які взагалі були потрібні користувачеві.

2) Precision@K

точність серед топ-K

Виражає частку корисних рекомендацій у виданому списку довжиною K.

3) HitRate@K

коефіцієнт влучання

Виражає факт успіху — чи зацікавила користувача хоча б одна позиція із виданого списку.

4) DCG@K

сукупний приріст

Виражає сумарну корисність списку з урахуванням позиційного дисконтування (штрафу за низьке положення).

5) NDCG@K

нормалізований сукупний приріст

Виражає міру близькості фактичного списку рекомендацій до ідеального можливого ранжування.

6) MRR

середній обернений ранг

Виражає швидкість знаходження першого потрібного товару (наскільки довго користувачеві довелося скролити перед першим кліком)

СЛАЙД 11

РЕЗУЛЬТАТИ ДОСЛІДЖЕННЯ PINTEREST (KDD 2018)

Method	Hit-rate	MRR
Visual	17%	0.23
Annotation	14%	0.19
Combined	27%	0.37
max-pooling	39%	0.37
mean-pooling	41%	0.51
mean-pooling-xent	29%	0.35
mean-pooling-hard	46%	0.56
PinSage	67%	0.59

В таблиці представлено результати з дослідження Pinterest (KDD 2018). Зверніть увагу на перші три рядки. Якщо ми спираємося виключно на зображення (Visual) або лише на текст (Annotation), точність низька — Hit-rate складає всього 14–17%. Коли ми об’єднуємо обидва сигнали (Combined), Hit-rate зростає до 27%, а MRR — до 0,37.

Простий перехід до базової GNN (mean-pooling) одразу піднімає Hit-rate із 27% до 41%. Додавання адаптивного навчання на важких негативах (mean-pooling-hard) дає ще +5% до Hit-rate. Повна індуктивна архітектура PinSage досягає 67% Hit-rate. MRR піднімається до 0,59.

СЛАЙД 12

ПОВЕДІНКА МОДЕЛЕЙ У СИТУАЦІЇ COLD START (ХОЛОДНИЙ СТАРТ)

1) Суть проблеми Cold Start. Поява нових користувачів або товарів у системі означає, що у графі взаємодій немає зв'язків (ребер) для цих нових вузлів.

2) Поведінка моделей

GraphSAGE

Відмінно (High Performance)

Генерує ембеддинги на основі атрибутів вузла (наприклад, текстовий опис товару, категорія, анкета користувача). Відсутність зв'язків у графі не блокує роботу агрегатора.

GAT

Задовільно (Moderate Performance)

Може використовувати початкові атрибути вузлів, але механізм Self-Attention не розкриває свій потенціал через відсутність сусідів для порівняння та зважування.

LightGCN

Критично / Не працює (Fails)

Повністю опирається на топологію графа та ID-ембеддинги. Якщо у нового вузла немає ребер, його ембеддинг залишається випадково ініціалізованим вектором.

3) ПРАКТИЧНИЙ ВИСНОВОК

Для рекомендаційних систем із частим Cold Start використовують гібридні підходи (наприклад, поєднання GraphSAGE для нових об'єктів та LightGCN для активної частини графа).

СЛАЙД 13

ОБМЕЖЕННЯ ТА ТЕХНІЧНІ РИЗИКИ ВПРОВАДЖЕННЯ GNN (ГРАФОВОЇ НЕЙРОННОЇ МЕРЕЖІ)

1) Обчислювальна вартість

Суть ризику: Навчання на великих графах потребує значних обсягів відеопам’яті, використання сусідського семплювання та складного конвеєра обробки.

2) Приватність: GDPR та Закон України «Про захист персональних даних»

Граф безпосередньо кодує історію дій, уподобання та соціальні зв’язки користувачів.

3) Обмеженість офлайн-оцінки

Оцінювання на статичному історичному датасеті не враховує динамічної поведінки користувача, зміни контексту та впливу інтерфейсу.

СЛАЙД 14

ІНЖЕНЕРНА ДОЦІЛЬНІСТЬ ТА ДОСВІД ІНДУСТРІЇ

У дослідженні 2018 року команда Pinterest та Стенфорду вперше довела життєздатність GNN у масштабі веб-сервісу:

МАСШТАБ СИСТЕМИ

Граф із **3 мільярдів** вузлів і **18 мільярдів** ребер.

Навчання на вибірці з **7,5 млрд** тренувальних пар.

Дослідження показало, що індуктивний граф із контентними ознаками вирішує проблему холодного старту значно краще за ізольований deep learning:

PinSage досяг **67% проти 27%** у найкращої комбінованої мультимодальної моделі на зображеннях і текстах.

MRR: зріс із **0,37** до **0,59**.

HIT-RATE

27% → 67%

MRR

0,37 → 0,59

СЛАЙД 15

ДЖЕРЕЛА ТА РЕСУРСИ

Наукові статті

- Ying R. et al. Graph Convolutional Neural Networks for Web-Scale Recommender Systems (PinSage). KDD, 2018
- Hamilton W., Ying R., Leskovec J. Inductive Representation Learning on Large Graphs (GraphSAGE). NeurIPS, 2017
- Veličković P. et al. Graph Attention Networks. ICLR, 2018
- He X. et al. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. SIGIR, 2020
- Wu S. et al. Graph Neural Networks in Recommender Systems: A Survey. ACM Computing Surveys, 2022
- Schein A. et al. Methods and Metrics for Cold-Start Recommendations. SIGIR, 2002
- Lika B. et al. Facing the cold start problem in recommender systems. Expert Systems with Applications, 2014

Дані та інструменти

- Amazon: датасет відгуків на телефонну продукцію
- PyTorch Geometric (бібліотека GNN)
- Stanford CS224W: Machine Learning with Graphs
- Дослідницький довідник команди з теми cold start

РЕПОЗИТОРІЙ ПРОЄКТУ

github.com/MariaZanko/CS101-Project

СЛАЙД 16

ВИСНОВКИ

Проблема

У нового товару немає взаємодій, тому CF і матрична факторизація не мають для нього навченого вектора.

Рішення

Гетерогенний граф (бренд, категорія, мітки) дає товару сусідів, а message passing — осмислений опис через них.

Моделі

GraphSAGE працює відмінно, GAT — задовільно, LightGCN без ребер не працює. На практиці поєднують підходи.

Індустрія

PinSage у Pinterest: Hit-rate 67% проти 27% у найкращої мультимодальної моделі без графа.

ГОЛОВНА ТЕЗА

GNN — не чарівна паличка: їй потрібні ознаки або зв’язки нового об’єкта. Також варто враховувати вартість, приватність і обмеженість офлайн-оцінки.

СЛАЙД 17

ДЯКУЄМО ЗА УВАГУ!

Будемо раді відповісти на ваші запитання

